

Visualización de la Información

Algunas nociones conceptuales

Germán Rosati - german.rosati@gmail.com
EIDAES-UNSAM / CONICET



¿Qué es un gráfico?

Crear una gramática


¿Qué es un gráfico?

¿Cómo podemos describir
sucintamente un gráfico?

¿Cómo podemos crear tal gráfico?

“los **principios fundamentales** de
un arte o una ciencia”

“**reglas y principios** que
gobiernan el uso de las lenguas y
la **organización** de las palabras
dentro de unas oraciones y otro
tipo de constituyentes sintácticos”



A Layered Grammar of Graphics

Hadley WICKHAM

A grammar of graphics is a tool that enables us to concisely describe the components of a graphic. Such a grammar allows us to move beyond named graphics (e.g., the “scatterplot”) and gain insight into the deep structure that underlies statistical graphics. This article builds on Wilkinson, Anand, and Grossman (2005), describing extensions and refinements developed while building an open source implementation of the grammar of graphics for R, `ggplot2`.

The topics in this article include an introduction to the grammar by working through the process of creating a plot, and discussing the components that we need. The grammar is then presented formally and compared to Wilkinson’s grammar, highlighting the hierarchy of defaults, and the implications of embedding a graphical grammar into a programming language. The power of the grammar is illustrated with a selection of examples that explore different components and their interactions, in more detail. The article concludes by discussing some perceptual issues, and thinking about how we can build on the grammar to learn how to create graphical “poems.”

Supplemental materials are available online.

Key Words: Grammar of graphics; Statistical graphics.

1. INTRODUCTION

What is a graphic? How can we succinctly describe a graphic? And how can we create the graphics that we have described? These are important questions for the field of statistical


datos

MAPEADOS
A

propiedades
estéticas

DE

objetos
geométricos



coordenadas

color

relleno

forma

puntos

barras

líneas

superficies

Transformaciones
estadísticas

Scatterplot de A y C

Además, forma en base a D

<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>
2	3	4	a
1	2	1	a
4	5	15	b
9	10	80	b

Scatterplot de A y C
Además, forma en base a D

A	B	C	D
2	3	4	a
1	2	1	a
4	5	15	b
9	10	80	b

Mapeo:

A => x

C => y

D => forma (shape)

x	y	Shape
2	4	a
1	1	a
4	15	b
9	80	b

Scatterplot de A y C

Además, forma en base a D

A	B	C	D
2	3	4	a
1	2	1	a
4	5	15	b
9	10	80	b

Mapeo:

A => x

C => y

D => forma (shape)

x	y	Shape
2	4	a
1	1	a
4	15	b
9	80	b

Escalar los datos en coordenadas que la computadora pueda interpretar y dibujar

$$\text{floor}\left(\frac{x - \min(x)}{\text{range}(x)} * \text{screen width}\right).$$

A	B	C	D
2	3	4	a
1	2	1	a
4	5	15	b
9	10	80	b


x	y	Shape
2	4	a
1	1	a
4	15	b
9	80	b

$$\text{floor}\left(\frac{x - \min(x)}{\text{range}(x)} * \text{screen width}\right).$$


Espacio estético (aesthetic space)

x	y	Shape
25	11	circle
0	0	circle
75	53	square
200	300	square

Objetos producidos



Plot final



Un esqueleto para construir un gráfico

```
df <- read_csv('./data/inputs_md/04_tasa_desoc.csv')
```

```
df_plot %>%
```

```
  ggplot(aes(x = fecha, y = tasa_desoc,  
             group = la_rioja_region,  
             color = la_rioja_region)) +
```

```
  geom_line(linewidth = 0.7) +
```

```
  scale_color_fundar_multi(name = "Región") +
```

```
  ylim(0, 20) +
```

```
  theme_monitor() +
```


```
  labs(title = ..., x = ..., y = ..., caption = ...)
```

Maapeo estético

Objeto geométrico

Escala X y Y

Otra nomenclatura: marcas y canales



- Una **marca** es el elemento geométrico primitivo que representa ítems o vínculos en una imagen. Las marcas se clasifican por la cantidad de dimensiones espaciales que requieren:
 - 0D: Puntos (point marks)
 - 1D: Líneas (line marks)
 - 2D: Áreas (area marks)
 - 3D: Volúmenes (poco frecuentes en InfoVis 2D)
- Cuando el dataset es una red (network), las marcas también pueden representar vínculos entre ítems:
 - Marcas de conexión (connection): una línea que muestra la relación entre dos ítems.
 - Marcas de contención (containment): un área que muestra relaciones jerárquicas por anidamiento.

➔ Points



➔ Lines



➔ Areas



- “Marcas” como primitivas geométricas

Los canales controlan la
apariciencia de las marcas

➔ **Position**

➔ Horizontal



➔ Vertical



➔ Both



➔ **Color**



➔ **Shape**



➔ **Tilt**



➔ **Size**

➔ Length



➔ Area




➔ Volume




- Un **canal** visual es una propiedad de las marcas que puede variar para transmitir información, generalmente varían de forma proporcional a algún atributo de los datos. Los canales son independientes de la dimensionalidad de la marca geométrica.
 - Posición espacial: posición en plano alineada, no alineada, profundidad 3D, región espacial.
 - Color: tiene tres sub-canales — matiz (hue), saturación y luminancia.
 - Tamaño: longitud (1D), área (2D), volumen (3D).
 - Orientación / inclinación (tilt / angle).
 - Curvatura.
 - Forma (shape).
 - Movimiento: dirección, velocidad, frecuencia de parpadeo.
 - etc.

- No todos los canales pueden transmitir la misma información al sistema perceptivo humano.




Atr 1: cuantit. / canal: altura
Atr 2: cualit / canal: pos. horiz.




Atr 1: cuantit. / canal: pos. y
Atr 2: cuantit / canal: pos. x

- ¿Qué atributos se representan?
- ¿Cuántos son cuantitativos?
- ¿Qué marcas hay en este gráfico?
- ¿Qué canales se usan?



Atr 1: cuantit. / canal: pos. y
Atr 2: cuantit / canal: pos. x
Atr 3: cualit / canal: color




Atr 1: cuantit. / canal: pos. vert.
Atr 2: cuantit / canal: pos. Horiz.
Atr 3: cualit / canal: color
Atr 4: cuantit / canal: radio


Channels: Expressiveness Types and Effectiveness Ranks

➔ **Magnitude Channels: Ordered Attributes**

Position on common scale



Position on unaligned scale



Length (1D size)



Tilt/angle



Area (2D size)



Depth (3D position)



Color luminance



Color saturation



Curvature



Volume (3D size)



Same

Same

Most
Effectiveness
Least

➔ **Identity Channels: Categorical Attributes**

Spatial region



Color hue



Motion




Shape




Channels: Expressiveness Types and Effectiveness Ranks

➔ **Magnitude Channels: Ordered Attributes**

Position on common scale




Position on unaligned scale



Length (1D size)



Tilt/angle



Area (2D size)



Depth (3D position)



Color luminance



Color saturation



Curvature



Volume (3D size)



Most

Effectiveness

Least

➔ **Identity Channels: Categorical Attributes**

Spatial region



Color hue



Motion




Shape



Ejercicio rápido


- Van a ver tres gráficos, para cada uno pensemos
 1. ¿qué atributos se representan?, ¿cuántos son cuantitativos?,
 2. ¿qué marcas hay?,
 3. ¿qué canales se usan?

Tasa de desocupación




Salario promedio de asalariados registrados (público y privado)

Privado Público



Fuente: Fundar, con base en la EPH (INDEC). Línea punteada: cambio de metodología de ingresos de la EPH (2015-2016); niveles a ambos lados no estrictamente comparables.

Hogares con Necesidades Básicas Insatisfechas (NBI)



Criterios para “medir” la efectividad

- Efectividad (*accuracy*): ¿qué tan bien podemos ver la diferencia entre los datos (items) representados?
- Discriminabilidad: ¿cuántos grupos o “saltos” o “bins” podemos diferenciar en una visualización?
- Separabilidad: ¿hay interferencia entre canales?
- Saliencia (*popout*): ¿hay algún elemento que “salte a la vista”?

Precisión

- Tendemos a interpretar mejor datos en una misma escala o con una escala de referencia
- Peor datos en ángulos
- Mucho peor, comparando datos representados como superficie.







Figure 5.8. Error rates across visual channels, with recent crowdsourced results replicating and extending seminal work from Cleveland and McGill [Cleveland and McGill 84a]. After [Heer and Bostock 10, Figure 4].

- Sobreestimamos las diferencias en datos representados como áreas

Wikipedia [2012]




- Dificultad en captar los cambios en las pendientes de rectas o curvas (muy dependiente de la relación entre los ejes)



Separabilidad


Posición +
Matiz (color)



Separable

2 grupos c/u


Tamaño +
Matiz (color)



Interferencia leve

2 grupos c/u


Ancho +
Altura



Interferencia media

3 grupos



Rojo + Verde



Interferencia alta

4 grupos


Separabilidad



- Añadir muchos canales visuales sobrecarga la capacidad del espectador
- Los diferentes canales interfieren entre sí


Saliencia (pop out)

Color Only, N=20




Saliencia (pop out)

Color Only, N=100




Saliencia (pop out)

Shape Only, N=20




Saliencia (pop out)

Shape Only, N=100




Saliencia (pop out)

Color & Shape, N=100




Saliencia (pop out)


Color Only, N=20




Color Only, N=100




Shape Only, N=20



Shape Only, N=100




Color & Shape, N=100



- En términos generales, es más difícil encontrar el puntito azul a partir del tercer panel, incluso comparándolo con un grande.
- El canal “color” parece ser el más efectivo en este punto

Saliencia (pop out)

- Muchos canales funcionan como “pop outs”:
 - Inclínación
 - grosor,
 - forma
- Pero otros no...
 - los pares de líneas paralelas no funcionan así



¿Qué factores afectan la precisión?

- Alineación
- Distancia
- Escalas comunes
- ...




¿Qué factores afectan la precisión?


- En general, nuestro sistema perceptivo funciona bien evaluando diferencias relativas, no absolutas.



Largo




Posición a lo largo de una escala no alineada



Posición a lo largo de una escala alineada


¿Qué factores afectan la precisión?

- En general, nuestro sistema perceptivo funciona bien evaluando diferencias relativas, no absolutas.
- La percepción de la luminancia (brillo) está basada en el “contexto”




¿Qué factores afectan la precisión?

- En general, nuestro sistema perceptivo funciona bien evaluando diferencias relativas, no absolutas.
- La percepción de la luminancia (brillo) está basada en el “contexto”



Bordes



Paletas



jet



RdYlGn



twilight



Pastel2



Paletas



plasma



inferno




magma



cividis



Paletas




uniform_viridis




uniform_plasma




not_uniform_jet




uniform_viridis



uniform_plasma




not_uniform_jet




Paletas

Gráfico 3. Cantidad de casos confirmados según fecha y edad (Mujeres)
Rojo a verde



Magma







Una paleta para La Rioja

```
FUNDAR_MULTI <- c(  
  "serie_1" = "#A8DCC8",    # 1. Resto país  
  
  "serie_2" = "#C8C87A",    # 2. NOA-Resto  
  
  "serie_3" = "#2D6E6E",    # 3. La Rioja (énfasis)  
  ...
```



```
la_rioja_region = case_when(  
  AGLOMERADO == "La Rioja" ~ "3. La Rioja",  
  AGLOMERADO != "La Rioja" & REGION == "Noroeste" ~ "2. NOA-Resto",  
  TRUE
```


Una paleta para La Rioja



Una paleta para La Rioja

- **La Rioja** es la única serie oscura. Las otras dos son claras y de baja saturación. => Saliencia por contraste de luminancia
- Los prefijos numéricos 1., 2., 3. fuerzan el orden alfabético del factor, y con eso el orden en que ggplot dibuja. **La Rioja** se dibuja última y queda encima de las otras dos cuando se cruzan => una solución a un problema de oclusión.

Una paleta para La Rioja

- ¿Qué pasaría si en vez del color/matiz/saturación hubiéramos usado la forma del punto para distinguir regiones?