

Clase 3

Del CSV al monitor

Construir los gráficos del monitor desde su CSV, y entender el flujo completo: de dónde salen los datos, qué cadena de scripts hay detrás, y qué hacer cuando sale un dato nuevo.

Germán Rosati - german.rosati@gmail.com

Fundar — grupo factor~data

Objetivo de la clase

Las clases 1 y 2 fueron sobre **el gráfico como objeto**. Esta es sobre **el flujo que lo produce**: qué archivo lo dibuja, de dónde salió el CSV que lee, qué cadena de scripts hay detrás, y qué tiene que hacer alguien de la provincia cuando sale un dato nuevo.

MANTENIMIENTO

Construir un gráfico del monitor desde su CSV.

COMUNICACIÓN

Saber qué advertencia va en el caption.

Es la clase donde los dos perfiles hacen cosas distintas pero acopladas — la práctica final los obliga a trabajar juntos.

Anatomía de un script de visualización

```
library(tidyverse)
source('style/fundar_monitor_theme.R') # 1. tema

df <- read_csv('data/inputs_md/
  12_mayor_25_superior.csv')
# 2. LEE un CSV

df_plot %>%
  ggplot(aes(x = fecha, y = porc_...,
    color = la_rioja_region)) +
  geom_line() +
  ylim(0, 35) +
  scale_color_fundar_multi() +
  theme_monitor() + # 4. el gráfico
  labs(title = "...",
    caption = fuente_fundar(...))

ggsave('outputs/plots/12_educ.png')
# 5. ESCRIBE un PNG
```

- **Todos los scripts de viz son el mismo archivo.** Cambia el CSV, la columna y, el ylim y los textos. Si sabés hacer uno, sabés hacer los diez.
- **El script no calcula el indicador.** El número ya viene hecho en el CSV — solo lo dibuja.
- **El PNG no es la única salida.** El dashboard no lee el PNG: lee el mismo CSV y lo vuelve a graficar.

La cadena completa



Por eso el CSV —y no el PNG— es lo que importa versionar.

Gráfico de líneas: lo que ya saben, y lo que lo vuelve del monitor

La gramática del gráfico de líneas ya se vio en la clase 1. Las cuatro decisiones que separan un gráfico de exploración de uno **del monitor**:

DECISIÓN	EN EL CÓDIGO	POR QUÉ
<code>factor(la_rioja_region)</code>	Fuerza el orden 1<2<3	La Rioja se dibuja última: queda por encima cuando las líneas se cruzan.
Eje Y en cero	<code>ylim(0, 35)</code>	Sin esto, <code>ggplot</code> recorta y exagera la variación (integridad visual).
Paleta del proyecto	<code>scale_color_fundar_multi()</code>	Sin esta línea, tres colores de igual peso y La Rioja no salta.
Eje X domado	<code>scale_x_discrete(breaks = quiebres_x)</code>	fecha es texto, 75 categorías → el truco deja 2 marcas por año.

Alternativa más robusta: `lubridate::yq(fecha) + scale_x_date()` — la que se usa en la práctica.

Bump chart: la pregunta que responde

¿En qué puesto está La Rioja respecto de las otras provincias, y cómo cambió ese puesto? — algo que la serie de tiempo no responde bien.

ES LA MISMA GRAMÁTICA QUE LAS LÍNEAS

data → aes → geom → scale → theme → labs. Un bump chart **es** un gráfico de líneas. Cambian tres cosas.

Datos: 15_pbg_per_capita_por_provincia.csv — 24 provincias × 15 años.

Bump chart: las tres cosas que cambian

1. **De valor a ranking** — el gráfico dibuja ranking, no pbg_per_capita: `mutate(ranking = min_rank(desc(pbg_per_capita)))` dentro de `group_by(año)`. El ranking es comparable entre años aunque el nivel no lo sea.
2. **scale_y_reverse()** — el puesto 1 va arriba, como lo espera el ojo.
3. **Patrón figura/fondo** — 24 líneas del mismo color son ilegibles: contexto en tono claro, NOA-Resto en tono medio, La Rioja gruesa y oscura, la única que se sigue punto por punto.

Reemplaza a la leyenda una etiqueta al final de la línea de La Rioja.

*El gráfico es soporte de una narrativa. Si el texto habla de cuatro cosas, no muestres doce. **La granularidad del gráfico tiene que igualar la del texto.***

Informe final Argendata, págs. 40–42

El gráfico es soporte de un texto

Caso ENGHo: el análisis publicado menciona cuatro rubros de consumo, el gráfico desagrega doce. La solución no es un gráfico más lindo: es **desagregar solo lo que el texto discute** y agregar el resto.

En el monitor pasa lo mismo con las cinco sub-dimensiones de NBI: hoy `13a_nbi_hogares`. R grafica solo el total, y está bien, porque el análisis habla del total.

Los tres campos de texto de un gráfico

CAMPO	QUÉ TIENE QUE DECIR	EJEMPLO
Título	El hallazgo, afirmado	"La desocupación en La Rioja se ubica por debajo del promedio del NOA desde 2021"
Subtítulo	Unidad, universo, período, transformación	"Desocupados como % de la PEA. Aglomerado La Rioja, 2007–2025, promedio de 4 ondas"
Caption	Fuente + advertencias metodológicas	"Serie interrumpida entre 2015-T3 y 2016-T1"

MEJOR EJEMPLO

03b_salarios_registrados_EPH.R: el caption marca el cambio de metodología de ingresos (2015-2016) y **el gráfico dibuja esa línea.**

PEOR EJEMPLO

04_desoc.R: el título es el nombre de la variable, no dice nada. Los diez indicadores tienen el mismo problema.


La Rioja es un dominio chico de la EPH

- Nunca reportar un nivel a partir de **un solo trimestre**: promediar las cuatro ondas del año.
- Un 0,00 en una sub-dimensión de NBI **no significa "no hay privación"** — significa que la muestra no alcanza para medirlo.
- En el bump: un cambio de **un solo puesto** entre años consecutivos es probablemente ruido, no tendencia.

Si se publica, esta advertencia va en el caption.

**La lógica del monitor:
de dónde sale cada número**

Del dato crudo al gráfico publicado



Tres cosas para explicar del diagrama

1. **Por qué la EPH tiene tres etapas y no un script:** para poder re-ejecutar solo una parte. Recalcular un indicador no requiere volver a descargar ni relimpiar 19 años de microdatos.
2. **Por qué raw_data/ no se versiona** pero inputs_md/ sí: los microdatos pesan ~1 GB y se regeneran solos; los CSV agregados pesan poco y se revisan en un diff.
3. **La línea con la estrella es la frontera del taller.** Arriba: equipo de datos. Abajo: equipo de comunicación. El contrato es el CSV.

Las cuatro trampas

- **La descarga incremental no re-descarga.** Si agregás una variable, los `.rds` existentes no se actualizan — hay que borrarlos y volver a correr `00`.
- **El orden de `as.character()` en la limpieza.** Al revés, las comparaciones de texto dejan de matchear *en silencio, sin error*. El bug más difícil de detectar del pipeline.
- **El quiebre 2015/2016.** `PONDII0` no existe antes de 2016 — los niveles de salarios a ambos lados no son comparables.
- **La Rioja es un dominio chico.** Sub-dimensiones de NBI en `0,00` por muestra insuficiente, no por ausencia de privación.

Las trampas 3 y 4 son exactamente lo que tiene que aparecer en el caption de un gráfico publicado.

Cómo se actualiza: el playbook

SALIÓ DATO NUEVO DE...	PASOS	FRECUENCIA
EPH continua	00_descarga_eph.R → 01 → 02_* → viz	Trimestral
SIPA	Reemplazar .xlsx → NN_prep_* → viz	Mensual
CEPAL / PBG	Reemplazar Excel → 15_prep_pbg.R → 15_prep_pbg_per_capita.R → viz	Cuando publiquen
OPEX, SRT, finanzas, educación	Reemplazar raw → prep → viz	Anual

Fuerza bruta cuando no se sabe qué se tocó: `source("src/999_run_pipeline.R")`.

El circuito de publicación

```
git checkout -b actualizo-eph-2026q2 # NUNCA sobre main
git add data/inputs_md/ outputs/plots/
git commit -m "Actualizo indicadores EPH, onda 2026-T2"
git push -u origin actualizo-eph-2026q2
# → abrir un Pull Request en GitHub
```

El push a main publica. El workflow de GitHub Actions renderiza el dashboard y lo publica en gh-pages — **actualizar un CSV republica el dashboard solo**. La rama y el PR permiten que otro mire el cambio antes de que salga.

Práctica integradora — en parejas de perfiles mezclados

1 · TERMINAR EL BUMP (MANTENIMIENTO LIDERA)

Cuatro huecos en `ejercicios/02_bump_pbg.R`: el `min_rank()`, el `scale_y_reverse()`, el `scale_linewidth_manual()` y la etiqueta final.

2 · SIMULACRO + RECORRIDO INVERSO (LOS DOS)

Fila ficticia en un CSV → correr el script → ver el PNG
extenderse → revertir con `git checkout`. Después: rastrear
tres números publicados hasta su fuente cruda.

Consigna completa en `practica.md` / `practica.Rmd`.

El mapa de pendientes del repositorio

- **Títulos que nombran variables** en vez de afirmar hallazgos — reescribir los diez `labs ( )`.
- **`scale_x_date ( )` en todos los scripts de viz** — media hora de trabajo, diez archivos.
- **El indicador 03 en pesos corrientes** — falta deflactar con IPC (el pendiente de mayor impacto).
- **Integrar los indicadores 17 y 18** al `informe/monitor_la_rioja.Rmd`.

1. Un gráfico es un mapeo de datos a propiedades visuales — los canales no son intercambiables.

2. La pregunta define la herramienta, y un gráfico claro igual puede mentir.

3. El circuito es reproducible de punta a punta: el CSV es el contrato entre los dos equipos.