

Visualización de la Información

El flujo de trabajo: del CSV al monitor

Germán Rosati - german.rosati@gmail.com
EIDAES-UNSAM / CONICET

Objetivo de la clase

- Las clases 1 y 2 fueron sobre **el gráfico como objeto**.
- Esta es sobre **el flujo que lo produce**:
 - qué archivo lo dibuja,
 - de dónde salió el CSV que lee,
 - qué cadena de scripts hay detrás y
 - qué tiene hay que hacer cuando sale un dato nuevo.

MANTENIMIENTO

Construir un gráfico del monitor desde su CSV.

COMUNICACIÓN

Saber qué advertencia va en el caption.

Anatomía de un script de visualización

```
library(tidyverse)
source('style/fundar_monitor_theme.R') # 1. tema

df <- read_csv('data/inputs_md/
  12_mayor_25_superior.csv')          # 2. LEE un CSV


df_plot %>%
  ggplot(aes(x = fecha, y = porc_...,
             color = la_rioja_region)) +
  geom_line() +
  ylim(0, 35) +
  scale_color_fundar_multi() +
  theme_monitor() +                    # 4. el gráfico
  labs(title = "...",
        caption = fuente_fundar(...))

ggsave('outputs/plots/12_educ.png')

# 5. ESCRIBE un PNG
```

- **Todos los scripts de viz son el mismo archivo.** Cambia el CSV, la columna `y`, el `ylim` y los textos. Si sabés hacer uno, sabés hacer los diez.
- **El script no calcula el indicador.** El número ya viene hecho en el CSV, solo lo dibuja. Por eso el CSV, y no el PNG, es lo que importa versionar.

La cadena completa



lo inserta con `mostrar("outputs/plots/12_educ.png")` -> por eso el CSV, y no el PNG, es lo que importa versionar.


datos

MAPEADOS
A

propiedades
estéticas

DE

objetos
geométricos



coordenadas

color

relleno

forma



puntos

barras

líneas

superficies

Transformaciones
estadísticas

Recordatorio: la gramática de gráficos

En la clase 1 vimos que un gráfico se arma con un número chico de piezas que, combinadas, generan cualquier gráfico posible => una **gramática**. En código, es `src/04_desoc.R` línea por línea:

```
df <- read_csv('./data/inputs_md/04_tasa_desoc.csv') # 1. ???

df_plot %>%
  ggplot(aes(x = fecha, y = tasa_desoc,                # 2. ???
             group = la_rioja_region,
             color = la_rioja_region)) +
  geom_line(linewidth = 0.7) +                        # 3. ???
  scale_color_fundar_multi(name = "Región") +         # 4. ???
  ylim(0, 20) +                                       # 4. ???
  theme_monitor() +                                  # 5. ESTILO DEL GRÁFICO
  labs(title = ..., x = ..., y = ..., caption = ...) # 6. ANOTACIONES
```

ggplot2: "gg" es *grammar of graphics*. El + es el operador que compone las capas de la gramática, y por eso los diez scripts de viz del repo son la misma receta con distintos ingredientes.

Recordatorio: la gramática de gráficos

En la clase 1 vimos que un gráfico se arma con un número chico de piezas que, combinadas, generan cualquier gráfico posible => una **gramática**. En código, es `src/04_desoc.R` línea por línea:

```
df <- read_csv('./data/inputs_md/04_tasa_desoc.csv') # 1. DATOS

df_plot %>%
  ggplot(aes(x = fecha, y = tasa_desoc,                # 2. MAPEO ESTÉTICO
            group = la_rioja_region,
            color = la_rioja_region)) +
  geom_line(linewidth = 0.7) +                        # 3. OBJETO GEOMÉTRICO
  scale_color_fundar_multi(name = "Región") +         # 4. ESCALA (dato → color)
  ylim(0, 20) +                                       # 4. ESCALA (dato → posición y)
  theme_monitor() +                                  # 5. ESTILO DEL GRÁFICO
  labs(title = ..., x = ..., y = ..., caption = ...) # 6. ANOTACIONES
```

ggplot2: "gg" es *grammar of graphics*. El + es el operador que compone las capas de la gramática, y por eso los diez scripts de viz del repo son la misma receta con distintos ingredientes.

¿Dentro o fuera de aes () ?

- La distinción que separa un **mapeo** (depende del dato) de una **decisión constante** (no depende de nada):

DENTRO DE aes() → MAPEO

```
color = la_rioja_region
```

El color **depende de una columna** del dato: cada valor de `la_rioja_region` se traduce a un color distinto.

FUERA DE aes() → CONSTANTE

```
linewidth = 0.7
```

El grosor es **fijo**: no varía con ningún dato, es una decisión de diseño igual para todas las líneas.

- Confundir estos dos es el error más común al arrancar con `ggplot2`.
- Va a volver en el bump chart: ahí el grosor de línea **sí** depende del dato (`linewidth = la_rioja_region, dentro de aes()`).

Gráfico de líneas: lo que ya saben, y lo que lo vuelve del monitor

- Aplicando la gramática que acabamos de repasar a un CSV nuevo. Las cuatro decisiones que separan un gráfico de exploración de uno **del monitor**, y viven casi todas en la capa de ESCALA, son:

Decisión	En el código	Por qué
factor(la_rioja_region)	Fuerza el orden 1<2<3	La Rioja se dibuja última: queda por encima cuando las líneas se cruzan.
Eje Y en cero	ylim(0, 35)	Sin esto, ggplot recorta y exagera la variación (integridad visual).
Paleta del proyecto	scale_color_fundar_multi()	Sin esta línea, tres colores de igual peso y La Rioja no salta.
Eje X domado	scale_x_discrete(breaks = quiebres_x)	fecha es texto, 75 categorías → el truco deja 2 marcas por año.

- Alternativa más robusta: `lubridate::yq(fecha) + scale_x_date()` => es la que se usa en la práctica.

Bump chart: la pregunta que responde

- ¿En qué puesto está La Rioja respecto de las otras provincias, y cómo cambió ese puesto?
- Es algo que la serie de tiempo no responde bien: muestra el nivel, pero no si se está ganando o perdiendo posiciones.
- También se lo llama **slopegraph de ranking**: una familia de gráfico de líneas donde el eje Y es la **posición** de cada unidad en un ranking, año a año.
- El repo lo usa en `src/15_pbg_ranking_percapita.R` para el PBG per cápita.
- **Datos:** `15_pbg_per_capita_por_provincia.csv` => 24 provincias × 15 años (2010–2024).

El script completo del bump chart

```
library(tidyverse)
source("style/fundar_monitor_theme.R")

prov <- read_csv("data/inputs_md/15_pbg_per_capita_por_provincia.csv") # 1. LEE

rank_df <- prov %>%
  group_by(anio) %>%
  mutate(ranking = min_rank(desc(pbg_per_capita))) %>% # 2. TRANSFORMA
  ungroup()

ggplot(rank_df, aes(anio, ranking, group = provincia, color = la_rioja_region)) +
  geom_line(aes(linewidth = la_rioja_region)) +
  geom_text(data = etiqueta_lr, aes(label = ranking)) +
  scale_y_reverse(breaks = 1:24) +
  scale_color_fundar_multi() +
  scale_linewidth_manual(values = c(0.3, 0.5, 1.4)) +
  theme_monitor() + # 3. DIBUJA
  labs(title = "...", caption = fuente_fundar(...))

ggsave("outputs/plots/clase3_bump_pbg.png") # 4. GUARDA
```

- Es el mismo esqueleto de siempre:
- **lee → dibuja → guarda.**
- Lo único que se mete en el medio es un paso de **transformación** antes de graficar.

Comparación: el script de líneas vs. el del bump

12_EDUC.R — LÍNEA


```
LEE read_csv(csv)
DIBUJA geom_line() + scale_color_fundar_multi() +
theme_monitor()
GUARDA ggsave(png)
```

02_BUMP_PBG.R — BUMP

```
LEE read_csv(csv)
TRANSFORMA (nuevo) mutate(ranking =
min_rank(...))
DIBUJA geom_line() + geom_text() +
scale_color_fundar_multi() + scale_y_reverse() +
scale_linewidth_manual() + theme_monitor()
GUARDA ggsave(png)
```

- Comparten **LEE**, **GUARDA**, y hasta `scale_color_fundar_multi() + theme_monitor()` dentro de **DIBUJA**.
- El bump agrega un paso de **TRANSFORMA** antes de graficar, y dos capas de escala más (`scale_y_reverse()`, `scale_linewidth_manual()`).

Así se ve un bump chart



Cada línea es una provincia. El eje Y no es un valor: es el **puesto** en el ranking de ese año, con el 1° arriba. En este ejemplo, La Rioja arranca última y termina primera, el bump chart deja ver esa trayectoria de un vistazo, cosa que una tabla de valores anuales no logra.

Bump chart: la misma gramática, tres cambios

data → aes → geom → scale → theme → labs Un bump chart **es** un gráfico de líneas con tres cambios:

CAMBIO 1 DE 3 · DE VALOR A RANKING

```
rank_df <- prov %>%  
  group_by(anio) %>%  
  mutate(ranking = min_rank(desc(pbg_per_capita))) %>% # 1 = el más alto ese año  
  ungroup()
```

El gráfico **no dibuja `pbg\_per\_capita`**, dibuja `ranking`. Muchas veces el gráfico no grafica la columna que viene en el CSV, sino algo derivado de ella en el propio script de viz: acá es un ranking; en otros casos es un índice base 100, una media móvil, una variación interanual.

Por qué el ranking sí se puede comparar entre años aunque el nivel no. El PBG per cápita está en pesos constantes de 2004, así que el nivel ya es comparable, pero incluso si estuviera en pesos corrientes (como el salario del indicador 03), el **ranking dentro de un mismo año** sería inmune a la inflación, porque afecta a las 24 jurisdicciones por igual.

Cambio 2 de 3: el puesto 1 va arriba

```
ggplot(rank_df,  
       aes(anio, ranking,  
           group = provincia)) +  
  geom_line() +  
  scale_y_reverse(breaks = 1:24)
```

Un ranking se lee con **el mejor arriba**. Sin `scale_y_reverse()`, ggplot dibuja el eje Y de manera creciente hacia arriba y el puesto 1 queda **abajo**.

- El resultado se lee al revés de como lo espera el ojo: subir de puesto se vería como "bajar" en el gráfico.

Cambio 3 de 3: el patrón figura/fondo

24 líneas del mismo color son ilegibles. La solución es la misma paleta regional del monitor: las provincias de contexto en un tono claro que no se puede seguir individualmente, y La Rioja destacada.


- **Contexto** (21 provincias) — línea fina, tono claro.
- **La Rioja** — línea gruesa, la única que se sigue punto por punto.

```
ggplot(rank_df, aes(anio, ranking, group = provincia, color = la_rioja_region)) +  
  geom_line(aes(linewidth = la_rioja_region)) +  
  scale_color_fundar_multi() +  
  scale_linewidth_manual(values = c(0.3, 0.6, 1.4)) # contexto fino, La Rioja gruesa
```

Como el CSV ya trae `la_rioja_region`, el mapeo sale directo. Reemplaza a la leyenda una **etiqueta al final de la línea** de La Rioja (`geom_text` sobre el último año, con `coord_cartesian(clip = "off")`).

Ranking del PBG per cápita provincial

Posición entre las 24 jurisdicciones · pesos constantes de 2004 · 2010-2024 · destacadas La Rioja y NOA-Resto



Fuente: Fundar, con base en CEPAL / Ministerio de Economía (VAB provincial a precios de 2004) y DNAP (proyecciones de población). Destacadas: La Rioja y NOA-Resto (Catamarca, Jujuy, Salta, Santiago del Estero, Tucumán).

Bump chart: preguntas

¿POR QUÉ GROUP = PROVINCIA Y NO GROUP = LA_RIOJA_REGION?

¿QUÉ PASA SI SACO SCALE_Y_REVERSE()?

NO PUEDO DISTINGUIR LAS 18 PROVINCIAS DEL "RESTO PAÍS" ENTRE SÍ. ¿ES UN PROBLEMA?

Bump chart: preguntas

¿POR QUÉ GROUP = PROVINCIA Y NO GROUP = LA_RIOJA_REGION?

Porque hay 24 líneas, una por provincia; el color agrupa de a tres pero la línea es por provincia.

¿QUÉ PASA SI SACO SCALE_Y_REVERSE()?

El gráfico se da vuelta y "subir en el ranking" se ve como bajar.


NO PUEDO DISTINGUIR LAS 18 PROVINCIAS DEL "RESTO PAÍS" ENTRE SÍ. ¿ES UN PROBLEMA?

No: son contexto. La pregunta del gráfico es sobre La Rioja, no sobre el resto.

El gráfico es soporte de una narrativa. Si el texto habla de cuatro cosas, no muestres doce. **La granularidad del gráfico tiene que igualar la del texto.**

El gráfico es soporte de un texto

Comparación del gasto de consumo de los hogares por finalidad del gasto (en porcentaje), 1996/1997- 2004/2005 - 2017/2018



Fuente de datos: Encuesta Nacional de Gastos de los Hogares, INDEC.

Nota: se incluyen localidades de 5.000 y más habitantes.

El gráfico es soporte de un texto

“Los patrones de consumo de la población se modifican a lo largo del tiempo, producto de razones tecnológicas, culturales, demográficas y económicas.

En Argentina, **los alimentos y las bebidas no alcohólicas** pasaron de explicar el 28,8% del gasto de los hogares en 1996-1997 al 22,6% en 2017-2018. Cuando se actualice metodológicamente el IPC (tomando las pautas de consumo de 2017-2018), los alimentos tendrán un peso menor que el que tienen actualmente. En contraste, en las últimas décadas ganaron peso rubros como **vivienda, transporte y comunicaciones**. Estos cambios en la estructura del consumo se deben a varios factores.

Por un lado, la suba del poder adquisitivo del período habilitó consumos en rubros “no esenciales”, como el **transporte propio**. Por otro lado, desde la década de 1990 hubo cambios tecnológicos que masificaron ciertos consumos, como celulares e internet (razón que explica por qué subió sostenidamente el peso de comunicaciones). En tanto, el rubro de vivienda ganó protagonismo fruto del mayor porcentaje de inquilinos en la población total y el mayor gasto en servicios públicos como **electricidad, gas y agua.**”

El gráfico es soporte de un texto

- El análisis publicado menciona cuatro rubros de consumo, el gráfico desagrega doce.
- La solución no es un gráfico más lindo: es **desagregar solo lo que el texto discute** y agregar el resto.
- En el monitor pasa lo mismo con las cinco sub-dimensiones de NBI: hoy `13a_nbi_hogares.R grafica solo el total`, y está bien, porque el análisis habla del total.



Los tres campos de texto de un gráfico

Campo	Qué tiene que decir	Ejemplo
Título	El hallazgo, afirmado	"La desocupación en La Rioja se ubica por debajo del promedio del NOA desde 2021"
Subtítulo	Unidad, universo, período, transformación	"Desocupados como % de la PEA. Aglomerado La Rioja, 2007–2025, promedio de 4 ondas"
Caption	Fuente + advertencias metodológicas	"Serie interrumpida entre 2015-T3 y 2016-T1"


MEJOR EJEMPLO

03b_salarios_registrados_EPH.R:
el caption marca el cambio de metodología
de ingresos (2015-2016) y **el gráfico
dibuja esa línea.**

Los tres campos de texto de un gráfico

Remuneración privada registrada en términos reales

Índice Ene-2025 = 100 · Desestacionalizado y deflactado por IPC · base ene-2025 = 100




Fuente: Fundar, con base en SIPA (Capital Humano) e IPC (INDEC/SSPM). Desestacionalizado (saca el efecto del aguinaldo) y en términos reales. >100 = más poder de compra que ene-2025; <100 = menos. Hasta sep-2025 (oct+ del Excel: salto atípico / 2026 duplica meses y contamina la SA).

La Rioja es un dominio chico de la EPH


- Nunca reportar un nivel a partir de **un solo trimestre**: promediar las cuatro ondas del año.
- Un 0,00 en una sub-dimensión de NBI **no significa "no hay privación"** — significa que la muestra no alcanza para medirlo.
- En el bump: un cambio de **un solo puesto** entre años consecutivos es probablemente ruido, no tendencia.
- Si se publica, esta advertencia va en el caption.

La lógica del monitor: de dónde sale cada número



Del dato crudo al gráfico publicado

La EPH (Encuesta Permanente de Hogares, INDEC) es la fuente de la mitad de los indicadores del monitor. No es la única fuente, pero es la única con **tres** etapas en vez de una.



Zoom: las tres etapas de la EPH, script por script

ETAPA 1 · DESCARGA

00_descarga_eph.R

Descarga incremental de microdatos trimestrales con el paquete `eph`.
Si el `.rds` del trimestre ya existe, lo saltea.

→ `data/raw_data/eph/*.rds` — no versionado, ~1 GB

ETAPA 2 · LIMPIEZA

01_limpieza_eph.R

- Canoniza tipos y nombres de columnas.
- Deriva variables (ej. `mayor_25_superior`).
- El orden de `as.character()` importa (trampa 2).

→ `data/proc_data/eph_*.rds` — no versionado

ETAPA 3 · CÁLCULO

02_indicadores_eph_*.R

- Un bloque de código por indicador.
- Pondera por `PONDERA` / `PONDIIO` según el indicador.


→ `data/inputs_md/*.csv` — ★ versionado ★

Por qué tres scripts y no uno: para poder re-ejecutar solo una parte. La descarga completa tarda varios minutos; recalcular un indicador sobre datos ya limpios, segundos.

Decisiones tomadas para el diseño del flujo


- **Por qué la EPH tiene tres etapas y no un script:** recalculando un indicador no requiere volver a descargar ni relimpiar 19 años de microdatos. Las fuentes no-EPH son más chicas y colapsan a un solo prep.
- **Por qué raw_data/ no se versiona** pero inputs_md/ sí: los microdatos pesan ~1 GB y se regeneran solos; los CSV agregados pesan poco y se revisan en un diff — si un indicador cambia, se ve exactamente en qué.
- **La línea con la estrella es la frontera del taller.** El contrato es el CSV: si tiene las columnas esperadas y los datos correctos, las dos mitades trabajan en paralelo sin pisarse.

Recorrido inverso: de un punto del gráfico al código



Caso normal: gráfico → CSV → script que calculó el CSV → limpieza → descarga

Recorrido inverso, más corto: el bump



Caso especial: gráfico → ranking calculado al vuelo → CSV con valores → prep → fuentes crudas

Tres cuestiones a tener en cuenta...

- **La descarga incremental no re-descarga.** Si agregás una variable, los .rds existentes no se actualizan => hay que borrarlos y volver a correr 00.
- **El quiebre 2015/2016.** PONDIIIO -variable de ponderación de ingresos- no existe antes de 2016 => los niveles de salarios a ambos lados no son comparables.
- **La Rioja es un dominio chico.** Sub-dimensiones de NBI en 0,00 por muestra insuficiente, no por ausencia de privación.

Cómo se actualiza

Salió dato nuevo de...	Pasos	Frecuencia
EPH continua	00_descarga_eph.R → 01 → 02_* → viz	Trimestral
SIPA	Reemplazar .xlsx → NN_prep_* → viz	Mensual
CEPAL / PBG	Reemplazar Excel → 15_prep_pbg.R → 15_prep_pbg_per_capita.R → viz	Cuando publiquen
OPEX, SRT, finanzas, educación	Reemplazar raw → prep → viz	Anual

Fuerza bruta cuando no se sabe qué se tocó: `source("src/999_run_pipeline.R")` .

El circuito de publicación

```
git checkout -b actualizo-eph-2026q2 # NUNCA sobre main
git add data/inputs_md/ outputs/plots/
git commit -m "Actualizo indicadores EPH, onda 2026-T2"
git push -u origin actualizo-eph-2026q2
# → abrir un Pull Request en GitHub
```

- El push a `main` publica. El workflow de GitHub Actions renderiza el sitio y lo publica => **actualizar un CSV dispara esa republicación sola.**
- La rama y el PR permiten que otro mire el cambio antes de que salga.

Práctica integradora — en parejas de perfiles mezclados

El foco es leer, no escribir: nada de código para completar en clase, eso queda como refuerzo opcional para la casa.

1 · LECTURA DE GRÁFICOS

Antes/después del gráfico de líneas, y errores de integridad plantados en el de desocupación — se identifican sin ver el código.

2 · PREDICCIÓN

Cuatro variantes del código del bump: predecir qué cambia en el gráfico antes de leer la respuesta.

3 · DEL PIPELINE EN GENERAL

Mapear la cadena de un indicador nuevo (tasa de empleo) y decidir en qué archivo tocaría cada cambio — sin correr nada.

Consigna completa en `practica.md`.

Cerrando este proceso...

- Un gráfico es un mapeo de datos a propiedades visuales => los canales no son intercambiables.
- La pregunta define la herramienta, y un gráfico claro igual puede mentir.
- El circuito es reproducible de punta a punta.